

# 成员分工及主要贡献说明

参赛成员以 A、B、C 表述。三人各负责一块主要工作，其余为协作或专项贡献。下列分工是实际完成情况，可与仓库中的设计文档、代码和测试结果对照。

| 成员 | 主要模块                |
|----|---------------------|
| A  | OS 移植与 sched_ext 调度 |
| B  | 绑核隔离、量化对比与不同负载测试    |
| C  | 自动化评测与 llama 调度调研   |

## 1. 分工总览

| 工作                 | 负责人          | 主要材料                                                                                   |
|--------------------|--------------|----------------------------------------------------------------------------------------|
| 环境准备与使用方法          | A、B、C        | docs/setup/、 hardware/README.md                                                        |
| 板卡选型               | B            | docs/setup/板卡选型.md                                                                     |
| OS 移植              | A            | docs/setup/OS调研.md、 docs/setup/OS移植方法.md                                               |
| sched_ext 调度支持     | A            | src/scheduler/、 tests/sched_ext/                                                       |
| 调度思路；绑核与隔离的实现和测试   | 思路 A，实现与测试 B | src/benchmark/bench_runner.py、 tests/test/                                             |
| bpf 追踪 V 状态切换      | A、B          | src/tracker/、 docs/tracker/bpftrace使用调研.md                                             |
| V 状态开销量化           | A、C          | src/benchmark/quantification.py、 tests/quantification/、 tests/rvv/*_Summary_VState.csv |
| 量化对比（含 x8...       | B            | docs/x86-vstate/、 docs/tracker/量化相关脚本/量化相关脚本.md                                        |
| 量化测试、自动化测试、连续批处理测试 | C            | src/benchmark/benchmark_llama.py、 docs/benchmark/性能评测指南.md、 tests/rvv/                 |
| 测试                 | B            | tests/test/                                                                            |
| llama-server 调度调研  | C            | docs/scheduler/llama-server请求调度与PD线程级优化分析.md                                           |

| 工作                            | 负责人 | 主要材料                      |
|-------------------------------|-----|---------------------------|
| llama-server - Cr / -Crb 无法绑核 | B   | docs/llama-server-cr-fix/ |

## 2. 共同完成

环境准备由 A、B、C 共同完成，并共同维护使用方法。B 负责板卡选型，选定 Milk-V Jupiter (SpacemiT K1, RVV 1.0, VLEN=256)。

| 材料                                | 内容                                       |
|-----------------------------------|------------------------------------------|
| docs/setup/QEMU环境搭建.md            | QEMU 中运行 openEuler 与 llama.cpp           |
| docs/setup/WSL安装llama.cpp.md      | WSL 上的 llama.cpp 环境                      |
| docs/setup/板卡选型.md                | BananaPi BPI-F3 与 Milk-V Jupiter 对比及选型结论 |
| docs/setup/milkV_jupiter硬件使用说明.md | 板卡使用方法                                   |
| hardware/README.md                | 硬件配置、QEMU CPU 参数、CPU governor            |

Git 提交规范见 AGENTS.md ，由全员执行。

## 3. A： OS 移植与 sched\_ext 调度

A 的主要模块是 OS 移植和 sched\_ext 调度支持，并提供绑核、隔离和 V 状态感知调度的思路。V 状态切换的 bpf 追踪与 B 共同完成，开销量化与 C 共同完成。

### 3.1 OS 移植

在 Milk-V Jupiter 上整理可用系统并完成移植，使后续 bpfttrace 与 sched\_ext 能在真实 RVV 硬件上运行。

| 材料                   | 内容                                                                  |
|----------------------|---------------------------------------------------------------------|
| docs/setup/OS调研.md   | openEuler、openKylin、openHarmony、Irradium 等镜像与内核情况                   |
| docs/setup/OS移植方法.md | Irradium 的 U-Boot/内核与 openEuler rootfs 的移植步骤，以及开启 sched_ext 所需的内核配置 |

### 3.2 sched\_ext 调度支持

调度思路由 A 提出并实现为 `vec_affine_sched`：用 `uprobe` 识别 `ggml_compute_forward_mul_mat` 推理线程，将推理线程限制在 CPU 0–3，普通任务隔离到 CPU 4–7，推理线程使用更长的时间片。

| 材料                                                | 内容                                          |
|---------------------------------------------------|---------------------------------------------|
| <code>src/scheduler/vec_affine_sched.bpf.c</code> | 内核态 <code>sched_ext</code> 回调：选核、入队、派发、时间片  |
| <code>src/scheduler/vec_affine_sched.c</code>     | 用户态加载、 <code>uprobe</code> 附着与统计读取          |
| <code>src/scheduler/自定义调度.md</code>               | 痛点、设计目标和策略说明                                |
| <code>src/scheduler/README.md</code>              | 编译、运行和已集成的调度方法                              |
| <code>tests/sched_ext/</code>                     | CFS 与 <code>sched_ext</code> 、正常负载与高负载的对比结果 |

## 4. B：绑核隔离、量化对比与不同负载测试

B 的主要模块是 CPU 绑核、核心隔离、量化对比和不同负载测试。板卡选型、x86 对照和 `llama-server -Cr / -Crb` 修复也由 B 完成。`bpf` 追踪与 A 共同完成。

### 4.1 选型与跨平台调研

| 材料                                             | 内容                                        |
|------------------------------------------------|-------------------------------------------|
| <code>docs/setup/板卡选型.md</code>                | 板卡对比与选型                                   |
| <code>docs/scheduler/RISC-V名词解析与调度概述.md</code> | hart、V 状态、上下文切换和向量寄存器保存/恢复                |
| <code>docs/x86-vstate/x86架构下的_V状态_.md</code>   | x86 XSAVE 向量状态与 RVV V 状态的对照，以及向量状态保存的判定口径 |

量化对比由 B 完成，记录在 `docs/tracker/量化相关脚本/量化相关脚本.md` 的 RISC-V / x86 分组中，并与 `docs/x86-vstate/x86架构下的_V状态_.md` 的判定方法对应。

### 4.2 bpf 追踪

与 A 共同完成。B 完成跟踪方案调研和 `save/restore` 探测脚本。

| 材料                                        | 内容                                                    |
|-------------------------------------------|-------------------------------------------------------|
| <code>docs/tracker/bpftrace使用调研.md</code> | <code>riscv_v_vstate_save</code> 调用路径，以及不依赖未导出符号的追踪方法 |
| <code>src/tracker/vstate_trace.bt</code>  | 全局 V 状态 <code>save/restore</code> 统计                  |

| 材料                              | 内容                                 |
|---------------------------------|------------------------------------|
| src/tracker/vstate_trace_cpu.bt | 按 CPU、进程和线程统计，用于检查绑核后非目标核上的 V 状态切换 |

### 4.3 绑核、隔离与不同负载测试

调度思路由 A 提供。B 实现并测试 CPU 绑定和核心隔离，覆盖 taskset、cgroup cpuset、partition-root、systemd-scope，以及配合 chrt 的 SCHED\_BATCH / SCHED\_FIFO。

| 材料                                           | 内容                                                               |
|----------------------------------------------|------------------------------------------------------------------|
| docs/tracker/CPU_affinity_cgroup.md          | affinity 与 cpuset 的设置方法                                          |
| docs/llama-server-cr-fix/-Cr_-Crb 无效的解决方案.md | llama-server 中 -Cr / -Crb 未传入线程池的原因，以及在 load_model 中补挂带亲和性线程池的改法 |
| src/benchmark/bench_runner.py                | 单组配置下轮换绑核/调度方法，采集 TPS、TTFT、P95 和 V-state                         |
| src/benchmark/bench_runner_all.py            | 按多组配置批量执行上述方法                                                    |
| src/benchmark/README_bench_runner.md         | 运行器配置与方法顺序                                                       |
| tests/test/                                  | group1–group10 的方法对比结果                                           |

不同负载测试由 B 完成。tests/test/README.md 中十组配置变化模型规模、线程数、绑定核心、prompt 长度、输出长度和并发，每种方法重复 3 次。

## 5. C：自动化评测与 llama 调度调研

C 的主要模块是自动化评测和 llama-server 调度调研，并完成量化测试与连续批处理测试。V 状态开销量化与 A 共同完成。

### 5.1 调度调研

| 材料                       | 内容                                        |
|--------------------------|-------------------------------------------|
| docs/scheduler/CFS调度.md  | CFS 的 vruntime 与公平调度，及其对推理线程抢占的影响         |
| docs/scheduler/其他调度策略.md | SCHED_FIFO、SCHED_RR、SCHED_BATCH 与 CFS 的差异 |

| 材料                                                            | 内容                                                             |
|---------------------------------------------------------------|----------------------------------------------------------------|
| docs/scheduler/llama-server请求调度与PD线程级优化分析.md                  | slot 状态机、<br>server_batch /<br>llama_ubatch、-<br>t / -tb 的选择条件 |
| docs/scheduler/figures/llama_server_slot_state_machine.drawio | slot 状态机图                                                      |

## 5.2 量化测试与自动化测试

量化测试和自动化测试由 C 完成。benchmark\_llama.py 支持 QEMU、本机和远程板卡，并在远程模式下自动启停 llama-server，输出轮次汇总和逐请求结果。

| 材料                               | 内容                                          |
|----------------------------------|---------------------------------------------|
| src/benchmark/benchmark_llama.py | 普通 benchmark 与自动化实验矩阵                       |
| docs/benchmark/性能评测指南.md         | 指标口径、控制变量、矩阵参数和结果字段                         |
| tests/rvv/                       | 1B/3B/8B 模型规模实验，以及 3B 在 p2/p4/p8/p16 下的并发扫描 |
| tests/README.md                  | 上述结果与 WSL 基线的索引                             |

实验矩阵固定每 slot context、线程数、prompt 和 cache 策略，分别只改变模型规模或 --parallel。V-state 与吞吐、延迟在同一轮请求上统计，对应 tests/rvv/\*\_Summary\_VState.csv。这部分开销结果与 A 共同完成。

## 5.3 连续批处理测试

连续批处理测试由 C 完成。自动化矩阵启动的 llama-server 带有 --cont-batching。请求如何进入同一 batch、以及并发 Decode 时 -t 与 -tb 的实际选择，写在 docs/scheduler/llama-server请求调度与PD线程级优化分析.md；对应测试结果在 tests/rvv/。

## 6. 材料对照

| 贡献        | 核对位置                                                                                                |
|-----------|-----------------------------------------------------------------------------------------------------|
| 环境与选型     | docs/setup/、hardware/README.md                                                                      |
| OS 移植     | docs/setup/OS移植方法.md                                                                                |
| sched_ext | src/scheduler/vec_affine_sched.bpf.c、<br>src/scheduler/vec_affine_sched.c、tests/sched_ext/README.md |
| bpf 追踪    | src/tracker/vstate_trace.bt、src/tracker/vstate_trace_cpu.bt                                         |

| 贡献             | 核对位置                                                                                   |
|----------------|----------------------------------------------------------------------------------------|
| V 状态开销         | src/benchmark/quantification.py、 tests/quantification/、 tests/rvv/*_Summary_VState.csv |
| x86 量化对比       | docs/x86-vstate/x86架构下的_V状态_.md、 docs/tracker/量化相关脚本/ 量化相关脚本.md                        |
| 绑核与隔离          | src/benchmark/bench_runner.py 中的方法列表、 tests/test/group1/ - group10/                    |
| -Cr / -Crb     | docs/llama-server-cr-fix/-Cr_-Crb 无效的解决方案.md                                           |
| 不同负载           | tests/test/README.md 的十组参数                                                             |
| llama 调度与连续批处理 | docs/scheduler/llama-server请求调度与PD线程级优化分析.md、 src/benchmark/benchmark_llama.py         |
| 自动化评测          | docs/benchmark/性能评测指南.md、 tests/rvv/                                                   |